

互助学习环境下可抗恶意评价的同伴互评算法*

赵鸣铭^{1a}, 王 聪^{1b}, 李 敏^{1a 2†}

(1. 四川师范大学 a. 计算机科学学院; b. 影视与传媒学院, 成都 610068; 2. 电子科技大学 网络与数据安全四川省重点实验室, 成都 610054)

摘要: 受学习者能力和意愿等主观因素的影响, 互助学习环境下同伴互评结果与真实评价通常存在显著差距。为了提高同伴互评的质量, 避免互评过程中利益驱动的恶意评价, 引入少量由教师预评分的作业作为哨兵。通过评审人对哨兵的评审情况, 以评审人的信誉评价作为权重向量, 并利用阈值进行截尾, 从而实现了恶意评价的有效隔离。真实测评数据上的实验结果证明, 相较于当前主流的互评算法, 该算法能有效过滤恶意高评或低评, 并且能适应较大数量级的学习者进行互评。在未来的研究中, 将针对信誉模型的优化进行深入研究。

关键词: 同伴互评; 互助学习; 恶意评价

中图分类号: TP391

文献标志码: A

文章编号: 1001-3695(2020)08-013-2305-05

doi: 10.19734/j.issn.1001-3695.2019.03.0055

Peer grading algorithm against malicious evaluation for collaborative learning

Zhao Mingming^{1a}, Wang Cong^{1b}, Li Min^{1a 2†}

(1. a. Computer Science College, b. College of Movie & Media, Sichuan Normal University, Chengdu 610068, China; 2. Network & Data Security Key Laboratory of Sichuan Province, University of Electronic Science & Technology of China, Chengdu 610054, China)

Abstract: Influenced by subjective factors such as learner's ability and willingness, there is usually a significant gap between peer review results and real evaluation in a collaboration learning environment. In order to improve the quality of peer review and avoid the interest-driven malicious evaluation in the process of mutual evaluation, this paper introduced a small number of teachers' pre-scoring assignments as sentinels. Through the reviewer's review of the sentinel, it used the reviewer's reputation evaluation as the weight vector and used the threshold for truncation, thus effectively separating the malicious evaluation. The experimental results on the real evaluation data prove that compared with other mainstream mutual evaluation algorithms, the algorithm can effectively filter malicious high evaluation or low evaluation and can adapt to a larger number of learners to conduct mutual evaluation. In future research, an in-depth study will be conducted on the optimization of the reputation model.

Key words: peer grading; collaborative learning; malicious evaluation

0 引言

Coursera、edX 和 Udacity 等慕课 (massive open online courses, MOOC) 应用的发展, 极大提升了人类知识积累与分享的效率, 快速改变着教育行业的基本面貌^[1]。慕课作为互联网下一个市场容量高达千亿的现象级风口, 在国内也催生了如网易云课堂/公开课 (<https://m.study.163.com/>)、学堂在线 (<http://www.xuetangx.com/>) 等优秀产品。然而受限于经济压力, 许多公益性质的课程, 无法针对学习者的个体差异, 来进行精细化指导与辅助。在较高的师生比之下, 让老师对每个学生进行单独的评估是极其不现实的^[2], 所以必须依赖学习社团内的相互帮助指导。由此, 为应对慕课教学环境下的评测难题, 以 Coursera 为代表的互助学习 (collaborative learning)^[3] 类应用通常通过引入同伴互评 (peer grading) 机制, 引导学习者使用系统的评分标准对彼此的作业进行评价, 并提供反馈。不过在具体的学习中, 学习者对同伴互评的准确性和权威性, 一直不能得到完全的公认。考虑到同伴互评是学习者完全自主的评价, 评价过程中学习者的认真程度和评价质量, 显然难以得到保证。因此如何分析多份互评成绩, 让同伴互评的结果更加可信, 是研究同伴互评机制的核心问题。

同伴互评的一个类似场景是科研论文或成果互评, 其目的

是考察论文或手稿的创新性、有效性和潜在影响力^[4]。同伴互评是学术交流系统中核心的组成, 其重要性是显而易见的。然而即使评审人和被评人均为受过严谨科学训练的科学家同行, 其评审的有效性也未能得到完全的公认^[5]。近年来同伴互评的评价方式和处理方法逐渐引起关注^[6], 其中一个关键问题在于, 不同的评价方法, 甚至流程中不同的透明程度, 都将影响同伴互评最终的结果^[7]。

且研究人员对科研论文的同行评审机制, 与学习者对作业同伴互评的研究有着一定的差别。在学习者对作业互评的情景中, 学习者未接受过分级培训, 这意味着他们存在不同水平的评分能力^[7]。部分研究者发现, 让学习者不直接给出评价结果, 而是对待评作业进行排序, 能有效提升互评的质量^[8-11]。文献^[7]根据对作业的排序提出 ordinal peer-grading 的互评算法, 有效地提升了互评质量。也有部分学者, 针对传统的评分 (例如给一个分数) 提出通过统计学习的方法提高互评质量^[12]。但同伴互评仍面临着学习者在评分过程中存在评分尺度不一致的问题。例如学习者可能对 80 分的构成有一个尺度, 且这种尺度可能是非线性的, 因为 100 和 95 之间的差异可能与 60 和 55 之间的差异不同^[7]。同伴互评的过程中, 学习者评分时主观意见占比较高, 学习者对待互评的认真程度不同, 会对最终的互评结果产生巨大的影响。更进一步地, 由于

收稿日期: 2019-03-12; 修回日期: 2019-04-08 基金项目: 国家自然科学基金资助项目 (61602331); 四川省重点实验室开放课题 (NDSMS201606); 四川省教育厅重点项目 (17ZA0322); 四川省教育厅科研项目 (17ZB0361)

作者简介: 赵鸣铭 (1993-), 女, 重庆人, 硕士, 主要研究方向为数据挖掘和大数据分析; 王聪 (1981-), 男, 山东滨州人, 副教授, 博士, 主要研究方向为教育大数据与知识图谱; 李敏 (1978-), 女 (通信作者), 四川峨眉人, 副教授, 博士, 主要研究方向为教育大数据与信息安全 (lm_turnip@126.com)。

评审背后可能存在的潜在利益(包括但不限于更高的成绩,以及由此带来的就业、升职等方面的优势),导致评审人存在恶意高评或低评他人作业的动机。如目前在国内的电商平台(www.taobao.com)上已出现针对如 Github 等泛知识社区中特定用户或项目刷赞(star)的业务,从而帮助特定用户在求职过程中获取更高的薪酬。然而评审过程中存在的恶意评价问题,目前尚未得到足够的关注。

针对以上问题,本文首次研究了恶意评价的攻击手段,并提出了利用哨兵机制的评审人信誉度生成算法,通过信誉截尾的方式隔离恶意评价,提升评审的有效性。主要贡献如下:a)将正常评审人的主观偏差和恶意评审人的评价分别视为不同性质的噪声,并在同伴互评中模拟噪声环境,模拟已存在的两个实际问题(每个评审人的评分尺度不同和认真程度不同),让本文算法在有较多噪声的环境下运行,验证该算法的可靠性;b)本文建立基于哨兵机制的抗恶意评价同伴互评算法,可有效处理上述问题,提升同伴互评的质量,让最终的互评结果更加接近学习者的真实得分。

1 背景知识

1.1 当前主流算法

2014 年 Raman 等人^[7]在著名学术会议 KDD 上提出了 ordinal peer-grading(OPG)算法,被认为是一种有效的同伴互评算法。该算法评估学习者成绩问题时,没有采用传统的评分方法,而是建立了排序模型。将序数对等分级问题,表示为一种聚合问题,然后探索了几种概率模型,用于评估学习者的成绩和评审人的可靠性。OPG 算法与同伴互评中经典的 Mallows's(MAL)模型、BradleyTerry(BT)模型、Thurstone's(THUR)模型,以及 Plackett-Luce(PL)模型都进行了对比,算法优化效果明显,但该算法中评审人与被评审人都是不同的群体,且 OPG 算法仅能面对较小数量的学习者。针对以上问题,2017 年,Capuano 等人^[13]提出了基于模糊群决策分析(fuzzy group decision making,FGDM)的 OPG 算法。FGDM 算法中,评审人和被评审人都为同一群体,且 FGDM 算法与基于序数的算法 MAL、BT、PL 以及现有的其他同伴互评算法如 CPA、borda count 等都进行了对比,实验结果表明,在重建正确排名和评估学生成绩方面,与其他算法相比,表现更好。FGDM 算法也根据学习者的数量,进行了实验,实验表明当学习者人数较少(100 左右)的时候,算法表现更好。这表明 FGDM 和 OPG 算法都存在共同的问题,即不能面对较大数量的学习者。而在现有 MOOC 环境中,同一门课程,学习者可能超过万人(例如学堂在线的《C++ 语言程序设计基础 2019 春》课程,参与人数达到 2.6 万人)。而本文提出的抗恶意评价的互评算法(against malicious evaluation,PG_AME),针对 MOOC 环境现状,可有效地解决此问题,能适应较大数量级的学习者互评。

1.2 主观评价尺度差异性

在同伴互评中,对同一份作业依据同一个标准,不同的评审人最终的评分结果却存在着较大的差异。这种差异的来源包括以下两个方面:a)评审人在评分过程中是否秉持认真客观的态度;b)不同的评审人对同一分数的构成尺度有不同的定义,即评审人主观尺度差异性。

例如评审人 A、B、C 需要根据标准的评分规则进行评分,他们对作业 x 的评分(从算法的四大特性评价)如表 1 所示。从表 1 可以看出 A、B、C 三人,对准确性、可读性、时间复杂度、扩展性的理解不一样,导致同一份作业,最终评分不一致。可见,主观尺度的差异性会对评审结果带来较大的偏差。而如何校正主观尺度带来的差异,弱化主观尺度对评分结果带来的偏差和不公,是本文研究的核心内容。

表 1 作业评分表

Tab. 1 Score sheet

评审人	准确性	可读性	时间复杂度	扩展性	总分
A	30	10	15	10	65
B	35	10	20	20	85
C	30	15	15	15	75

注:准确性(0~40分);可读性(0~20分);时间复杂度(0~20分);扩展性(0~20分);满分100分。

1.3 恶评人

除了上述主观尺度差异性,导致互评偏差的另一种情况便是恶评人的恶意评价。互助学习中的学习者,从行为本身来看,可以分为正常评审人和恶意评审人两大类。

定义 1 正常评审人,指该评审人产生的行为事件,为正常合理的,例如根据所给的标准评分规则,对其他作业进行评分。每个正常评审人会有自己的主观尺度,因此正常评审人的主观尺度与教师的主观尺度仍存在差异。

定义 2 恶意评审人(恶评人),指该评审人产生了不符合规范的异常行为事件,例如因为私人原因(贪图方便、恶意报复、老好人思想),不按照评分标准,给所评作业一个不实的分数。此时该评审人给出了不真实成绩,该行为严重影响了互评的最终结果,导致被评审的学习者得到不公平的对待,影响其最终得分。

1.4 作业评价模型

在互助学习中,数据是指评审人给同伴评价的分数。而噪声数据则指与标准分数相差较大的分数。在引言部分,已经提出同伴互评中,出现较大偏差的原因有每个评审人主观尺度的差异性和评审人评分时的认真程度。将评审人的主观感知差异和恶意评价视为评价数据中蕴涵的噪声,给出如下定义。

定义 3 白噪声数据(white noise data)。在一组同伴互评数据中,正常评审人因主观尺度与教师的主观尺度存在偏差,进而给出的分数与标准分数存在差异,这种差异数据即白噪声数据。白噪声通常服从或近似服从 $N(0, \sigma^2)$ 。

定义 4 色噪声数据(color noise data)。在同伴互评中,恶评人所给出的评分数据,则为色噪声数据。该噪声可以通过外界原因(例如加强对评审人的监督)进行控制。受恶评人主观控制,色噪均值通常不为 0,其分布律未知。

由此可得:在同伴互评中,无法得知该评审人在评分过程中的操作是否符合规范,从而无论是白噪声数据还是色噪声数据,都同时存在于原始数据中。而噪声数据越多,对最终评估学习者得分的影响越大,使最终的结果越偏离期望值。本文通过哨兵机制模型,可以筛选出一定量的噪声数据,从而提升同伴互评的质量,使最终的实验结果更加接近期望值。

1.5 同伴互评模型

图 1 显示了传统的同伴互评模型。在该模型中,一个评审人评审多份不同的作业;另一方面,一份作业也会被不同的评审人评审,该份作业的评分来自于几个评审人共同的评价结果。

理想的互评模型可定义为

$$\begin{cases} s_i = f(S_i) \\ S_i = [s_{i1}, s_{i2}, \dots, s_{in}] \\ s_{ij} = \hat{s}_i + n_{ij} \end{cases} \quad (1)$$

其中: s_i 是评价模型给予作业 i 的评价; S_i 是评审人对作业 i 的评审成绩集合,在此以向量形式表示,其每个元素 s_{ij} 是评审人 j 给予作业 i 的个体评价; $f(\cdot)$ 是由评审人个人评价到模型评价的映射; \hat{s}_i 是一个隐含变量,视为该作业的真实评价; n_{ij} 是评审人 j 的主观评价误差。于是,互评问题可以表述为,如何优化 $f(\cdot)$,使得 $\forall S_i$,有评价误差 $E(s_i - \hat{s}_i) \rightarrow 0$ 。当不存在恶评

人时,显然有

$$\lim_{j \rightarrow \infty} \sum_j n_{ij} = 0 \quad (2)$$

即,当样本量足够大时,取评分的算术均值即可得到 \bar{s}_i 的一个较优估计。然而当存在恶意评价时,噪声 n_{ij} 需要细分为白噪声 w_{ij} 和色噪 c_{ij} 。由于色噪的非0均值特征,评审结果将会产生显著误差。

$$n_{ij} = w_{ij} + c_{ij} \quad (3)$$

2 攻击模型

一组原始的同伴互评数据中,可能存在少量的噪声数据。而为了验证本文算法在存在色噪的环境中能体现出其稳定性和优越性,本章将人为模拟攻击环境,随机加入特定比例的恶评数据。首先建立模拟攻击模型,对原始数据集进行模拟攻击。具体做法是污染原始数据,插入特定比例的高评或低评分值,为本文算法提供一个色噪环境,以此来检验算法在色噪环境下的生存能力。图2描述了模拟攻击模型,哭脸的评审人为模拟的恶评人。恶评人给出的所有评分均为有色噪声数据,用虚线箭头表示。在有噪声的环境下,一份作业的评分主要由以下三种来源:a)全部为正常评审人的评分;b)既有正常评审人的评分,又有恶评人的评分;c)全部为恶评人的评分。



图1 传统互评模型

图2 模拟攻击模型

Fig.1 Traditional peer-grading model Fig.2 Simulated attack model

篡改数据方式,依据评审人评分时的现实情境制定,分为恶意高评、恶意低评。恶意高评是指,使用该用户节点的所有评分都大于95分;恶意低评是指,使用该用户节点的所有评分都低于20分。

3 同伴互评算法

本文同伴互评算法基本思想是:通过哨兵机制给每个评审人一个信誉度,再设立多个阈值,将对信誉度低于一定阈值的评审人评分进行隔离。根据信誉度和所给出的评分,可评估最终每个学习者的得分。整个算法的流程如图3所示。




图3 算法流程

Fig.3 Algorithm flowchart

而本文算法考虑到了国内互助学习环境中师生比过高的现实情况,通过建立哨兵机制,助教只需对少量哨兵作业进行评价,就可实现校正同伴互评中存在的噪声数据,提升互评的质量。本文算法的优势有:a)学习者与评审人是同一群体;b)每人仅需要评审少量作业,缓解了因评审量过大导致的评审质量下降问题^[14];c)可抵抗恶意评价解决评审结果存在显著差异的问题。

3.1 哨兵机制

为估计评审人的信誉,引入了哨兵机制。在互评过程中,预先选择一定数量具有代表性(优、中、差等)的作业作为哨兵,将哨兵作业混入正常待评作业,利用评审人对哨兵作业的评价质量,计算评审人的信誉值。哨兵机制具体模型如图4所示。

而加入哨兵机制后,模拟攻击模型有一定的变化。如图5

所示,加入哨兵机制后,恶评人对哨兵作业的评分均视为色噪数据。通过哨兵作业的标准得分,将评审人对哨兵作业的评分与哨兵作业的标准评分进行比较(以教师评分为基准分),从而计算出评审人的信誉度。



图4 哨兵机制模型

Fig.4 Sentinel mechanism model

图5 加入哨兵机制的攻击模型

Fig.5 Simulated attack based on sentinel mechanism model

3.2 建立用户信誉度算法

在同伴互评中,根据评审人对哨兵作业的评价情况,给每一位参与互评的评审人赋予一个信誉值,作为评价该评审人评分的准确性和认真程度。每一轮评分都与评审人当前的状态有关,评审人在每一轮评分时出现状态差异,也是不可控的。通过评审人每一轮评分情况,赋予当前状态的信誉度,以此衡量评审人当前评分的可信性。每提交一轮作业的互评结果,都会单独统计每个评审人当前的信誉度,以使每一轮评分都更靠近期望值。假设评审人 u 对哨兵的评分为集合 E_{uj} ,而教师(视为标准评分)对哨兵的评分为集合 \bar{E}_{uj} ,则评审人 u 对哨兵的评分与哨兵的标准分的均差 t_u 为

$$t_u = \frac{\sum_{j=1}^m |E_{uj} - \bar{E}_{uj}|}{m} \quad (4)$$

其中: m 表示哨兵的数量。求 t_u 具体的算法实现如下:

算法1 基于哨兵机制的差值算法

/* 集合 E 表示该评审人对哨兵作业的评分集合,集合 B 表示所有哨兵作业的标准评分*/

```
begin
     $t_0 \leftarrow 0$ 
    for  $i \leftarrow 1$  to  $m$  do
        if  $E_i - B_i > 0$  then
             $t_i \leftarrow E_i - B_i + t_{(i-1)}$ 
        else then
             $t_i \leftarrow B_i - E_i + t_{(i-1)}$ 
        end if
    end for
     $t \leftarrow t_i / m$ 
```

根据式(4),先计算出每个评审人与标准评分的差异程度,得到了 t_u 的值,随后利用该值求出评审人 u 的信誉度 Q_u 为

$$Q_u = \frac{100}{\frac{1}{t_{\min}} - \frac{1}{t_{\max}}} \times \left(\frac{1}{t_u} - \frac{1}{t_{\max}} \right) \quad (5)$$

其中: t_{\min} 和 t_{\max} 表示所有评测人与标准评分的均差最小值和最大值。最终得到的 Q 在0~100。具体算法实现如下:

算法2 求信誉度算法

/* 集合 T 表示所有评审人对哨兵评分与标准评分的差值,集合 Q 表示所有评审人的信誉值 n 为评审人总数*/

```
begin
     $\max \leftarrow 0$ ;
     $\min \leftarrow 100$ ;
    for  $i \leftarrow 1$  to  $n$  do
        if  $T_i > \max$  and  $T_i < \min$  then
             $\max \leftarrow T_i$ ,  $\min \leftarrow T_i$ 
        else if  $T_i > \max$  and  $T_i > \min$  then
             $\max \leftarrow T_i$ 
        else if  $T_i < \max$  and  $T_i < \min$  then
             $\min \leftarrow T_i$ 
        else then
            return
        end if
```

```

end for
for  $i \leftarrow 1$  to  $n$  do
     $Q_i = 100 / (1/\min + 1/\max) * (1/T_i - 1/\max)$ 
end for
end

```

3.3 阈值过滤机制

当获取了每个评审人的信誉度后,仍需要对其进行筛选和处理。若直接将所有评审人的信誉度代入至原始数据,再求出每个学习者最终加权平均值的的成绩,信誉度低的评审人的评分也会算入,导致与真实值仍存在一定量的偏差。本节提出通过阈值过滤掉信誉度低的评审人,将其所有的数据都进行隔离,不计入最终的结果。原理如图 6 所示。



图 6 阈值过滤方法

Fig. 6 Threshold filtering method

图 6 中清晰地表明了当评审人的信誉度小于阈值时,该评审人的所有评分数据都将被移除,不会影响其他正常数据,且该评审人进入隔离区。阈值主要通过以下三个标准进行设置: a) 使用该阈值后,得到的最终成绩与标准成绩的相关系数; b) 使用该阈值后,得到的最终成绩与标准成绩的相关 p 值; c) 使用该阈值后,是否每个学习者都有自己的成绩,需要保证数据的完整性。综合以上三个标准,完整性越高,相关系数越大,则可选出适当的阈值。

3.4 学习者得分计算方法

假设每个学习者最终收到的评分集合为 $G = \{G_1, G_2, G_3, \dots\}$, 则每个评分对应一个评审人,即每个评分 G_i 对应一个评审人的信誉度 Q_i 。最终学习者 u 的得分为

$$G = \frac{\sum_{i=1}^m G_i Q_i}{\sum_{i=1}^m Q_i} \quad (6)$$

其中: m 表示学习者 u 的作业有 m 个评审人对其进行评价。通过以上方式,可以计算出每个学习者的最终得分。

4 实验与讨论

参与本次实验计划有 200 名学习者,实际参与人数为 191 人,共同学习的课程为《数据结构》。专业教授选择了作业试题,学习者完成后上交再筛选出哨兵作业,然后将作业分发互评。为避免作弊行为的发生,整个互评过程是全匿名的。最终,收集到了 1 286 份评测结果,这些数据作为实验研究的基础数据。

4.1 模拟攻击实验

模拟攻击的具体设计如表 2 所示。从表 2 中可以看出模拟攻击有两种方式(第 2 章有详细的介绍),而针对这两种不同的方式,每种方式都对应篡改整体数据的 10%、20% 和 30%,所以最终得到了六组数据集,后续实验将针对这六组数据集进行处理。

表 2 模拟攻击设计方案
Tab. 2 Simulation attack design

模拟攻击	篡改 10%	篡改 20%	篡改 30%
恶意高评	数据集 1	数据集 2	数据集 3
恶意低评	数据集 4	数据集 5	数据集 6

4.2 阈值的过滤实验

3.3 节中提到阈值的选择,有三个标准。用恶意高评 10% 的数据集,做了三组实验,并通过 Pearson 相关分析和数据完整性检验得到如表 3 所示。在相关性实验中,相关系数绝对值越大,相关性越强,相关系数绝对值越接近 0,相关性越弱;当 p 值小于阈值(0.01)时,则存在显著相关性;当 p 值大于阈值(0.01)时,则不存在显著相关性。通过三组数据的对比,最终发现,当信誉值的阈值设置为 25 时,其相关系数、数据完整性越高,所以后续实验将直接设置信誉值的阈值为 25。

表 3 阈值过滤实验
Tab. 3 Threshold filtering experiment

阈值	相关系数	p 值	数据完整性/%
30	0.444 **	$P < 0.001$	96.00
25	0.545 **	$P < 0.001$	99.50
0	0.239 **	0.003	100.00

* $p < 0.05$ ** $p < 0.01$

4.3 实验效果

当确定阈值为 25 后,通过可信算法得出了每个学习者的最终的得分,实验结果如图 7 所示。实验是在不同的噪声环境里进行的。最终比较的是未使用任何算法和使用 PG_AME 算法后每个学习者的成绩与标准成绩(教师评分)的误差均值。




图 7 实验结果

Fig. 7 Experiment results

从图 7 可以看出,在恶意高评和恶意低评的环境里,PG_AME 算法在面对不同程度的恶意评价时,有一定的稳定性。当恶意高评数量不断增多,使用 PG_AME 算法后,误差均值较小范围的增加,渐近曲线与原始结果比更加平滑;当恶意低评数量增多时,使用 PG_AME 算法后,误差均值逐渐减少,而原始结果的误差均值逐渐增加。经分析,出现这种情况的原因是恶意低评时,低评分与平均分数相差较大,可信算法更容易筛选出恶意低评的恶评人,并将其隔离,从此可以反映出 PG_AME 算法的稳定性。当存在 30% 的数据为恶意低评时,使用 PG_AME 算法后计算出误差均值仅为 11.47 分;而未使用算法的原始数据误差均值为 13.14 分。此时,使用 PG_AME 算法后,在原始数据的基础上,误差均值减少了 12.71%,优化效果明显。整体来看使用 PG_AME 算法后,使最终成绩都在原基础上减少了 10% 以上的误差,提高了互评质量,达到了期望效果。

4.4 对比实验

本文 PG_AME 算法与主流 OPG、FGDM 算法进行了比较。在同一组数据集(20% 恶意高评数据集)下,具体的实验结果如图 8 所示。在与 OPG、FGDM 算法的对比中,当 20% 的数据为恶意高评时,使用 PG_AME 算法计算出误差均值仅为 10.94 分,标准误差为 14.8 分。而 OPG 算法计算出误差均值为 13.41 分,标准误差为 19.14,显著劣于原始结果的误差均值 12.71 分和标准误差 17.32 分;而 FGDM 算法与原始结果的误差均值和标准误差接近,由此可见在抗恶意评价方面,PG_AME 算法效果显然更佳。实验说明了 PG_AME 算法效果良好,可提升同伴互评最终效果。




图8 对比实验结果

Fig. 8 Compared experiment results

5 结束语

如何削弱评审人的主观观感对成绩客观性的影响是互助学习环境下同伴互评问题面临的一个关键挑战。针对这一问题,本文建立了基于哨兵机制的可抗恶意评价的同伴互评模型,将评审人对哨兵作业的评分与哨兵作业的标准分进行比较,从而计算出每个评审人的信誉度,以衡量评审人可信性。然后通过信誉度阈值的过滤,将信誉度低于标准阈值的评审人进行隔离,再计算出每个学习者最终的得分。相较于传统算法,本文算法有如下几点优势: a) 学习者和评审人为同一群体,更加适应国内 MOOC 教育的大环境; b) 减轻了助教的工作量; c) 可以抵抗恶评人的恶意评价,隔离有色噪声数据; d) 对因主观尺度偏差导致评分误差的白噪声数据进行了隔离处理,从而增强了同伴互评方法的评价质量。

参考文献:

- [1] Justin R. Rebooting MOOC research [J]. *Science*, 2015, 347(6217): 34-35.
- [2] Kulkarni C, Wei K P, Le H *et al.* Peer and self assessment in massive online classes [M] // Plattner H, Meinel C, Leifer L. Design Thinking Research. Cham: Springer, 2014: 131-168.
- [3] Miquel E, Duran D. Peer learning network: implementing and sustaining cooperative learning by teacher collaboration [J]. *Journal of Education for Teaching* 2017, 43(3): 349-360.
- [4] Price S, Flach P A. Computational support for academic peer review: a perspective from artificial intelligence [J]. *Communications of the ACM* 2017, 60(3): 70-79.
- [5] Tennant J P, Dugan J M, Graziotin D *et al.* A multi-disciplinary perspective on emergent and future innovations in peer review [J]. *F1000 Research* 2017, 6: 1151.
- [6] Ross-Hellauer T. What is open peer review? A systematic review [EB/OL]. (2017-04-27). <https://doi.org/10.12688/f1000research.11369.2>.
- [7] Raman K, Joachims T. Methods for ordinal peer grading [C] // Proc of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM Press, 2014: 1037-1046.
- [8] Tamblyn R, Girard N, Qian C J *et al.* Assessment of potential bias in research grant peer review in Canada [J]. *Canadian Medical Association Journal* 2018, 190(16): E489-E499.
- [9] Sikdar S, Marsili M, Ganguly N *et al.* Influence of reviewer interaction network on long-term citations: a case study of the scientific peer-review system of the journal of high energy physics [C] // Proc of ACM/IEEE Joint Conference on Digital Libraries. Piscataway, NJ: IEEE Press, 2017: 1-10.
- [10] Bhattacharya R, Ellis L M. It is time to re-evaluate the peer review process for preclinical research [J/OL]. *BioEssays*, 2018, 40(1). (2017-11-11). doi: 10.1002/bies.201700185.
- [11] Pan Yuangang, Han Bo, Tsang I W. Stagewise learning for noisy k -ary preferences [J]. *Machine Learning* 2018, 107(8): 1333-1361.
- [12] Huisman J, Smits J. Duration and quality of the peer review process: the author's perspective [J]. *Scientometrics* 2017, 113(1): 633-650.
- [13] Capuano N, Loia V, Orciuoli F. A fuzzy group decision making model for ordinal peer assessment [J]. *IEEE Trans on Learning Technologies* 2017, 10(2): 247-259.
- [14] Siler K, Strang D. Peer review and scholarly originality: let 1 000 flowers bloom, but don't step on any [J]. *Science Technology & Human Values* 2017, 42(1): 29-61.
- [15] Kizilcec R F, Halawa S. Attrition and achievement gaps in online learning [C] // Proc of the 2nd ACM Conference on Learning. New York: ACM Press, 2015: 57-66.
- [16] Brinton C G, Chiang M, Jain S *et al.* Learning about social learning in MOOCs: from statistical analysis to generative model [J]. *IEEE Trans on Learning Technologies* 2014, 7(4): 346-359.
- [17] Justin R, José A, Ruiperez-V. The MOOC pivot [J]. *Science* 2019, 363(6423): 130-131.
- [18] Erdt M, Fernández A, Rensing C. Evaluating recommender systems for technology enhanced learning: a quantitative survey [J]. *IEEE Trans on Learning Technologies* 2015, 8(4): 326-344.
- [19] 蒋卓轩, 张岩, 李晓明. 基于 MOOC 数据的学习行为分析与预测 [J]. *计算机研究与发展* 2015, 52(3): 614-628. (Jiang Zhuoxuan, Zhang Yan, Li Xiaoming. Learning behavior analysis and prediction based on MOOC data [J]. *Journal of Computer Research and Development* 2015, 52(3): 614-628.)
- [20] 周庆, 牟超, 杨丹. 教育数据挖掘研究进展综述 [J]. *软件学报*, 2015, 26(11): 3026-3042. (Zhou Qing, Mou Chao, Yang Dan. Research progress on educational data mining: a survey [J]. *Journal of Software* 2015, 26(11): 3026-3042.)
- [18] Qin Jiahui, Gao Huijun, Zheng Weixing. Exponential synchronization of complex networks of linear systems and nonlinear oscillators: a unified analysis [J]. *IEEE Trans on Neural Networks and Learning Systems* 2015, 26(3): 510-521.
- [19] 谢光强, 章云. 多智能体系统协调控制一致性问题研究综述 [J]. *计算机应用研究*, 2011, 28(6): 2035-2039. (Xie Guangqiang, Zhang Yun. Survey of consensus problem in cooperative control of multi-agent systems [J]. *Application Research of Computers*, 2011, 28(6): 2035-2039.)
- [20] 谢光强, 阳开, 李杨, 等. 基于切换拓扑的多智能体协作控制研究综述 [J]. *计算机应用研究* 2019, 36(4): 967-971. (Xie Guangqiang, Yang Kai, Li Yang *et al.* Review of research on multi-agent cooperative control based on switching topology [J]. *Application Research of Computers* 2019, 36(4): 967-971.)
- [21] Ando H, Oasa Y, Suzuki I *et al.* Distributed memoryless point convergence algorithm for mobile robots with limited visibility [J]. *IEEE Trans on Robotics and Automation*, 1999, 15(5): 818-828.
- [22] Vicsek T, Czirok A, Ben-Jacob E *et al.* Novel type of phase transition in a system of self-driven particles [J]. *Physical Review Letters*, 1995, 75(6): 1226-1229.
- [23] Dimarogonas D V, Johansson K H. Decentralized connectivity maintenance in mobile networks with bounded inputs [C] // Proc of IEEE International Conference on Robotics and Automation. Piscataway, NJ: IEEE Press, 2008: 1507-1512.
- [24] Ji Meng, Egerstedt M. Connectedness preserving distributed coordination control over dynamic graphs [C] // Proc of American Control Conference. Piscataway, NJ: IEEE Press, 2005: 93-98.
- [25] De Gennaro M C, Jadbabaie A. Decentralized control of connectivity for multi-agent systems [C] // Proc of the 45th IEEE Conference on Decision and Control. Piscataway, NJ: IEEE Press, 2006: 3628-3633.
- [26] Zavlanos M M, Egerstedt M B, Pappas G J. Graph-theoretic connectivity control of mobile robot networks [J]. *Proceedings of the IEEE*, 2011, 99(9): 1525-1540.
- [27] Ben-Naim E, Krapivsky P L, Redner S. Bifurcations and patterns in compromise processes [J]. *Physica D: Nonlinear Phenomena*, 2003, 183: 190-204.
- [28] Lorenz J. Continuous opinion dynamics under bounded confidence: a survey [J]. *International Journal of Modern Physics C* 2007, 18(12): 1819-1838.

(上接第 2304 页)