

基于表示学习的在线学习交互质量评价方法

王雪岑 张 昱 刘迎婕 于 戈

东北大学计算机科学与工程学院 沈阳 110169

(1871579@stu.neu.edu.cn)



摘 要 当今的教育模式发生着非常重大的变革,教育正在向泛在化、智能化、个性化的方向发展。以 Massive Open Online Courses(MOOCs)为代表的在线教育逐渐进入大众视野,在线教育中的交互性成为了决定在线学习质量的关键。研究表明,学习过程中的交互为学习者提供了有效且高效的帮助和支持,对学习过程的评价反馈可以有效地提高学习效果。在教育领域,对学习者和学习资源之间的交互进行建模至关重要,表示学习技术为学习者和学习资源之间的顺序交互建模提供了具体方案。文中首先建立在线学习的交互网络模型,然后使用两个循环神经网络将网络中的学习者和学习资源节点嵌入到一个欧氏空间中,并提出交互质量评价指标,以判断学习者的学习效果是否达到预期。在实际数据集上的实验证明了所提方法的有效性。

关键词: 表示学习;MOOCs;交互评价;教育大数据

中图法分类号 TP311.13;G434

Evaluation of Quality of Interaction in Online Learning Based on Representation Learning

WANG Xue-cen,ZHANG Yu,LIU Ying-jie and YU Ge

School of Computer Science and Engineering,Northeastern University,Shenyang 110169,China

Abstract The model of education today has undergone a very significant change,and education is developing in the direction of ubiquity,intelligence and individuation. Online education,represented by MOOCs,is gradually coming into the public field of vision,and the interactivity in online education has become the key to determine the quality of online learning. Some researches show that the interaction in the learning process provides efficient help and effective support for learners,and the feedback of learning process evaluation can effectively improve the interaction effect of learning. Modeling interactions between learners and learning resources is crucial in domains such as e-commerce. Representation learning presents a method to model the sequential interactions between learners and learning resources. Firstly,an interactive network of online learning is established. And then,the learners and learning resources can be embedded into a Euclidean space by using two recurrent neural networks. The evaluation index of the quality of interaction is proposed,which can judge whether the learner's learning effect is up to the expectation. The experiments on real datasets reveal the effectiveness of the proposed method.

Keywords Representation learning,MOOCs,Interactive evaluation,Big data in education

1 引言

随着“互联网+”时代的到来,在线学习逐渐成为当前的主流学习模式。大规模开放在线课程(Massive Open Online Course,MOOC)是在线学习的一种典型形式,具有双向交互的便捷性、教学资源的丰富性、教学互动的多样性等特点。在以 MOOC 为代表的在线学习平台中存在着大量的交互行为,例如观看课程视频、做测试、在论坛上讨论问题等。众多教育研究表明,交互是教与学重新整合的关键^[1],学习过程中知识的建立和形成依赖于交互的开展^[2],而有效的教学交互可以带来学习效果的提升。Ullah 等提出将交互正确地应用到在线课程中,能够为学习者拓展学习经验^[3],提供创建新意义

的机会。Su 等认为通过实现在线学习中有意义的学习交互能够促进学习者的知识建构^[4]。

20 世纪 80 年代以来,随着教育观念的逐渐变化,人们开始认为学习的质量不仅体现在学习的效果上,还体现在学习的过程中^[5],不仅要关注对学习的效果评价,更要关注对学习的方式和过程的评价。评价不仅可以对学习结果有价值判断作用,而且对学习具有显著的回流作用^[6]。在众多针对在线学习的评价研究中,专门针对交互质量的评价研究较少。目前,针对在线学习交互质量评价的主要研究模式依然遵循传统的教育学研究方法,即从多个角度提出交互质量的评价量规,然后通过以调查问卷为主的方法进行实验验证。这类方法存在难以实现评价自动化、评价指标定义宽泛、评价指标繁

到稿日期:2020-10-09 返修日期:2020-11-04 本文已加入开放科学计划(OSID),请扫描上方二维码获取补充信息。

基金项目:国家自然科学基金(U1811261);中央高校基本科研业务费专项资金资助(N180716010)

This work was supported by the National Natural Science Foundation of China(U1811261) and Fundamental Research Funds for the Central Universities(N180716010).

通信作者:张昱(zhangyu@mail.neu.edu.cn)

杂、评价指标信效度低等问题。此外, Siemens 从学习观的角度提出学习是一种以交互为中心的网络现象, 网络的形成依赖于交互的开展^[7]。近年来, 研究者以学习交互网络为基础, 通过网络数据挖掘和机器学习技术进行了大量的包括教学资源推荐、行为预测等在内的应用研究^[8-10], 而针对交互质量评价方法的研究则相对较少。

本文结合国内外教育大数据、教育交互和交互评价的发展现状和趋势, 以及近年来在教育大数据管理和动态嵌入方面的研究成果和经验, 借鉴国内外数据挖掘、神经网络和网络表示学习等领域的研究成果, 以实际应用为背景, 在理论和实践中进行创新性工作, 对在线学习交互质量的评价进行了研究。

本文提出了一种能够有效评估在线学习交互质量的方法, 可以为该问题的应用提供解决思路。本文着眼于对在线学习平台的主要主体——学习者和学习资源间的交互开展研究。本文方法首先以建立清晰的动态学习交互网络为基础, 然后通过表示学习方法对学习交互网络中的实体进行低维表示, 最后提出评价方法。

本文第 2 节评述了与本文研究相关的工作; 第 3 节和第 4 节分别介绍了交互网络构建和嵌入的方法; 第 5 节提出了交互质量评价指标; 第 6 节进行了实验和分析; 最后总结全文。

2 相关工作

2.1 交互质量评价

Moore 最早提出在线教学中的 3 种交互类型: 学习者和学习资料的交互、学习者和教师的交互、学习者和学习者的交互^[11]。在在线学习交互质量的评价研究中, 研究者主要在这 3 种交互的基础上提出各种评价指标。

Laurillard^[12]认为高等教育的教师必须在教学方法上更加专业, 并具有研究方面的专业精神。为改善教学和提高学生的学习效果, Laurillard 针对教学中的设计和使用的学习技术, 提供了一个良好的理论基础。但其侧重于对学习者的交互的学习环境的优缺点进行评价, 缺少对教学交互行为的分析。Roblyer 等^[13]通过量规的方法对交互水平进行定量评价, 从社会交互、教学交互、资源交互、信息质量等多个维度对课程交互质量进行评价, 提出了利用理论和研究的发现来设计评估在线课程交互质量的指标。但该量规的设计比较宽泛, 且具有教师和学生的主观性, 并不能保证足够的客观性和较高的可信性。Chen 等^[14]在教育研究学已有成果的基础上, 提出了根据媒介交互设计、学习者与学习资源的交互设计、社区交互设计、教师的参与度、学生参与度等 5 个维度的 47 个指标的在线学习交互质量评价指标体系, 而该理论研究的可信度和评价效果仍需实践验证。

与上述工作不同, 本文以学习者和学习资料的交互为目标, 以交互网络为基础, 提出了可计算的交互质量评价指标。

2.2 网络表示学习

近年来, 随着机器学习技术的发展, 网络嵌入技术引起了人们的广泛关注, 针对网络中节点的特征学习成为了一项新兴的研究任务, 针对网络的分析研究的一个关键问题就是如何合理地表示网络中的特征信息。

受 word2vec 的启发, DeepWalk 算法^[15]首次将深度学习

中的技术引入到了网络表示学习领域。DeepWalk 算法充分利用了网络结构中的随机游走序列的信息。Node2vec 算法^[16]通过改变随机游走序列生成的方式, 进一步扩展了 DeepWalk 算法。Struc2vec 算法^[17]在 Node2vec 算法的基础上可以有效地对远距离的具有结构相似性的节点进行建模。上述算法均是基于 Skip-gram 语言模型的表示方法。Hin2vec 算法^[18]是针对异构信息网络表示学习的框架, 与上述方法不同, Hin2vec 算法的核心是一个神经网络模型, 不仅可以学习网络中节点的表示, 还可以学习关系(元路径)的表示。表示学习为网络建模和推理提供了强有力的工具, 然而随着时间的推移, 上述单一的静态网络嵌入不足以代表网络的动态变化。

近年来, 有研究者^[19-20]在已有工作的基础上, 通过建立动态的网络模型并使用表示学习技术来捕捉网络节点的特征变化, 用于推荐和用户行为预测等。本文则是在动态的学习交互网络中使用表示学习技术对交互质量进行评价。

3 交互网络构建

许多现实场景可以抽象为一个图结构, 如社交网络、交通网络、用户与电子商务网站中物品的关系网络等。网络表示学习, 即网络嵌入, 是将网络节点投影到低维连续空间的方法, 同时保留了网络结构和固有特性, 即学习实体的低维嵌入, 用于表示学习者和学习资源的属性演化。学习者频繁与学习资源进行交互, 同一学习者可能在一段时间内与不同学习资源产生交互, 并且这些交互会随时间而变化, 因此这些交互就构成了学习者与学习资源之间的交互网络。

构建学习者和学习资源之间的动态交互网络是本文工作的基础, 通过表示学习方法可以对学习者与学习资源的动态演化进行建模。每位学习者和每一项学习资源都可以嵌入到一个欧氏空间, 随着时间的推移, 学习者与不同的学习资源进行交互, 学习者和学习资源的属性特征互相影响并共同发展。学习者和学习资源的属性特征会进一步影响未来学习者和学习资源之间的相互作用。

本文主要对学习者在过程中与学习资源交互的质量进行评价, 因此选取学习者-学习资源的交互数据为研究基础, 进而对学习过程中学习者的交互进行定量评价。

以 MOOC 平台为例, 学生的学习活动包括视频观看、页面导航、测验参与等交互行为。这些交互被记录为点击流日志, 每个点击流都是记录的集合。每条交互活动记录都可由学习者 ID、学习资源 ID、交互时间和交互特征向量组成, 其中交互特征向量包含了诸如查看文档、观看视频等交互信息。针对学习者在过程中与不同的学习资源之间的交互关系, 本文提出了图 1 所示的学习交互网络模型。




图 1 学习交互网络
Fig. 1 Learning interactive network

学习交互网络中包含学习者和学习资源两类节点, 两类

节点之间的连边代表了学习者和学习资源的交互。由于交互可能发生多次,且交互的类型特征并不相同,因此每条边都标记有交互时间、交互特征等信息。下文将给出学习交互网络的定义。

定义 1(学习交互网络) 学习交互网络表示为 $G=(u, i, e_{ui}(t, f))$, 其中 $u \in U$ 表示学习者节点, $i \in I$ 表示学习资源节点, e_{ui} 表示学习者节点与学习资源节点间交互时形成的边, 其中 t 和 f 分别表示交互时间和交互特征。

基于学习交互网络的定义, 给出网络中节点的嵌入表示形式。令向量 $u(t) \in \mathbb{R}^n$, $\forall u \in U$ 表示 t 时刻学习者嵌入表示, 向量 $i(t) \in \mathbb{R}^n$, $\forall i \in I$ 表示 t 时刻学习资源嵌入表示, $\forall t \in [0, T]$ 。学习者 $u \in U$ 和学习资源 $i \in I$ 在时刻 $t \in \mathbb{R}^+$ ($0 < t_1 < t_2 \cdots \leq T$) 时的交互活动特征向量由 f 表示。表 1 列出了下文所需的符号及其代表的含义。

表 1 本文所用的符号表示及其含义

Table 1 Symbols and meanings used in this paper

符号	含义
$u(t)$ 和 $i(t)$	学习者 u 和学习资源 i 在时间 t 的嵌入表示
$u(t^-)$ 和 $i(t^-)$	学习者 u 和学习资源 i 在时间 t 前的嵌入表示

4 交互网络嵌入

4.1 嵌入模型

本文首先通过循环神经网络模型(Recurrent Neural Network, RNN)学习学习者和学习资源的嵌入表示; 然后使用两个神经网络在每次交互时更新学习者和学习资源的嵌入, 将每个实体嵌入到欧氏空间中; 最后通过分析学习者嵌入属性的变化对学习交互质量提出了一种评价方法。

图 2 给出了本文提出的基于表示学习的在线学习实体嵌入模型。该模型分别使用两个 RNN 对嵌入进行更新, 分别为学习者 RNN 和学习资源 RNN。其中, 学习者 RNN 由所有学习者共享来更新学习者嵌入, 学习资源 RNN 由所有学习资源共享来更新课程资源嵌入。学习者、学习资源的嵌入由 RNN 的隐藏状态表示。




图 2 基于表示学习的在线学习实体嵌入模型

Fig. 2 Online learning entity embedding model based on representation learning

本文使用的 RNNs 是相互递归的, 嵌入结果初始化为 0。当学习者与学习资源发生交互时, 学习者 RNN 使用学习资源在时间 t 之前的嵌入学习资源 $i(t^-)$ 作为输入来更新学习者的嵌入 $u(t)$, 使用学习资源的动态嵌入可以很好地反映学习资源的当前状态, 从而实现更有意义的学习者嵌入和更简单的训练。基于同样的原因, 学习资源的嵌入使用学习者动态嵌入 $u(t^-)$ 即学习者在 t 时刻之前的嵌入来更新学习资源嵌入 $i(t)$, 这使得嵌入之间存在相互递归的依赖关系。

4.2 学习者和学习资源嵌入

学习者的嵌入由式(1)得到:

$$u(t) = \sigma(W_1^u u(t^-) + W_2^u i(t^-) + W_3^u f + W_4^u \Delta u) \quad (1)$$

其中, 矩阵 W_1^u, \dots, W_4^u 是学习者 RNN 的参数, 由训练得到; Δu 代表从学习者上一次与任何学习资源发生交互到当前发生交互的时间差; f 代表交互特征向量; σ 是非线性激励 sigmoid 函数; $u(t^-)$ 代表在时间 t 之前的学习者的嵌入表示; $i(t^-)$ 代表在时间 t 之前学习资源的嵌入表示。最终更新学习者嵌入 $u(t)$ 。

学习资源的嵌入由式(2)得到:

$$i(t) = \sigma(W_1^i i(t^-) + W_2^i u(t^-) + W_3^i f + W_4^i \Delta i) \quad (2)$$

其中, 矩阵 W_1^i, \dots, W_4^i 是学习资源 RNN 的参数, 由训练得到; Δi 代表学习资源上一次与学习者发生交互到当前发生交互的时间差; $i(t^-)$ 代表在时间 t 之前学习资源的嵌入表示; $u(t^-)$ 代表在时间 t 之前学习者的嵌入表示。最终更新学习资源嵌入 $i(t)$ 。

虽然式(1)、式(2)中的更新只涉及直接参与特定交互活动的学习者和学习资源对, 但是特定学习者或学习资源的影响可以传播到整个二分交互网络中。可以看出, 学习者的嵌入会影响直接发生交互的学习资源的嵌入, 那么更新后的学习资源嵌入会影响未来产生交互活动的不同学习者, 以此类推贯穿整个网络。

4.3 参数学习

循环神经网络的参数可以通过梯度下降方法进行学习。 t 时刻学习者嵌入学习的损失函数如下:

$$L_t = L(u(t), u(t^-)) \quad (3)$$

其中, L 为可微分的损失函数, 如均方误差(MSE)损失函数; $u(t)$ 为 t 时刻学习者嵌入的输出, $u(t^-)$ 为 t 时刻学习者嵌入的输入。采用随时间反向传播(Back Propagation Through Time, BPTT)算法来计算梯度。

5 交互质量评价

基于第 4 节中的学习者和学习资源嵌入表示结果, 本文从学习者学习效果的角度, 提出了一种适用性较广的可计算的交互质量评价指标。学习者与学习资源的交互活动越频繁, 其嵌入结果互相影响, 在欧氏空间得到的嵌入向量距离就越近。本文根据此提出了度量学习者的交互质量的评价指标, 如式(4)所示:

$$D(p) = \sum_{q \in (0, Q)} \|u(p) - i(q)\|_2 \quad (4)$$

其中, p 表示单一学习者, q 表示学习资源, Q 为学习资源数量。 $D(p)$ 值越小, 该学生的交互学习质量就越优, 而该值越大, 该学生的交互学习质量就越差。

为验证该指标的正确性, 基于交互质量与学习效果相关这一假设, 本文通过该指标预测学习者的状态。当学习者的学习状态较差(有退学的可能)时, 用户的标签为 1; 当学习状态较好时, 用户的标签为 0。对学生的交互评价指标 $D(p)$ 按降序排序, 预测精度(Precision)可通过计算排序后前 $N\%$ 的学习者中存在标签为 1 的学习者数量得到。

6 实验

6.1 实验数据集

本文的实验分析是在学堂在线的两个公开数据集上进行的。2013 年 10 月推出的学堂在线已成为中国最大的 MOOC

平台之一。当学习者在平台上学习一门课程时,系统会记录多种类型的交互活动,如观看视频、回答问题、完成作业等。

本文使用了 2 个数据集,第一个数据集来自于国际知识发现和数据挖掘竞赛 KDD CUP 2015,简称为 KDD15;第二个数据集来自于 Moocdata 平台,本文将第 2 个数据集称为 XTdata。实验数据集包括学习者/学习资源信息、以特征形式存在的交互信息、交互发生时间等。表 2 列出了两个数据集的统计信息。

表 2 实验数据集的统计信息

Table 2 Statistics of datasets

	KDD15	XTdata
学习者	7 047	6 371
学习资源	98	27
交互活动数	411 749	397 083
退学者	4 066	4 982

6.2 实验设置

本实验使用 PyTorch 实现 RNNs,采用 Adam 优化器对模型进行优化,其学习率为 0.001,采用修正线性单元(ReLU)作为激活函数,模型嵌入维数为 128 维,模型训练的次数为 50,在输入模型前所有的交互特征都被规范化。取数据集的前 60%作为训练集来训练模型,取 20%的数据作为验证集来评估模型,剩下的 20%的数据作为测试集来测试模型的泛化能力,最后选取性能最好的模型训练结果。作为对比,本文选取了 Deepwalk,Struc2vec,Hin2vec 这 3 种静态网络表示方法对学习者和学习资源对进行嵌入。

6.3 实验结果

本文在两个数据集上进行了实验,计算出了由式(4)定义的所有学习者的交互质量评价指标 $D(p)$,其分布情况如图 3 和图 4 所示。其中,横坐标为 $D(p)$ 的取值范围,纵坐标为 $D(p)$ 取值范围内的学习者数量。通过图 3 和图 4 可以看出,不同学习者的交互质量是不相同的,与 XTdata 数据集相比,KDD15 数据集上的 $D(p)$ 的取值范围跨度较大,学习者的交互质量区别较明显。




图 3 KDD15 数据集上的 $D(p)$ 统计分布

Fig. 3 Statistical distribution of $D(p)$ on KDD15 dataset




图 4 XTdata 数据集上的 $D(p)$ 统计分布

Fig. 4 Statistical distribution of $D(p)$ on XTdata dataset

在嵌入表示模型训练阶段,实验比较了训练模型在所有时期的性能,并选取了精度最高的训练结果。两个数据集的训练结果如图 5 和图 6 所示。其中,横坐标为训练次数,纵坐标为学习者状态预测的精度。




图 5 KDD15 数据集上模型精度的比较

Fig. 5 Comparison of model precision on KDD15 dataset




图 6 XTdata 数据集上模型精度的比较

Fig. 6 Comparison of model precision on XTdata dataset

由图 5 可以看出,当使用 KDD15 数据集训练到第 40 次时,在 N 分别取 5,10,20 时模型精度都是最高的。由图 6 可以看出,当使用 XTdata 数据集训练到第 36 次时,在 N 分别取 5,10,20 时模型精度也都是最高的。由此可知,随着训练次数的增加,模型的精度也逐渐升高,但训练次数过多时会导致实验过拟合,使模型精度下降,并且针对不同的数据集,精度达到最高的训练次数也不相同。

最后,本文将动态网络表示方法 RNNs 与其他静态网络表示方法进行了比较,结果如表 3 和表 4 所列。

表 3 KDD15 数据集上学习者状态预测结果

Table 3 Learner state prediction results on KDD15 dataset

Method	$N=5$	$N=10$	$N=20$
Deepwalk	0.306 83	0.321 02	0.410 22
Struc2vec	0.133 52	0.017 76	0.202 27
Hin2vec	0.519 89	0.537 59	0.551 06
RNNs	0.553 97	0.622 69	0.626 70

表 4 XTdata 数据集上学习者状态预测结果

Table 4 Learner state prediction results on XTdata dataset

Method	$N=5$	$N=10$	$N=20$
Deepwalk	0.799 37	0.803 77	0.805 34
Struc2vec	0.793 10	0.805 34	0.808 47
Hin2vec	0.755 48	0.767 66	0.755 10
RNNs	0.952 98	0.879 12	0.839 87

通过对比表 3 和表 4 可以看出,本实验所提出的动态网络交互评价方法具有可扩展性。针对学习者状态预测的精度在不同数据集上的表现存在差异,分别统计了两个实验数据集中不同学习状态的学习者的平均交互次数,如表 5 所列。可以看出,XTdata 数据集中学习者节点与学习资源节点间的影响更为明显,最终 XTdata 数据集的实验精度较 KDD15 数

数据集的实验精度更高。但相比静态网络表示方法,本文的评价模型在两个数据集上的精度都分别有很大程度的提升,表现最佳。

表5 学习者平均交互次数的统计信息

Table 5 Statistics of average number of learner interactions

	KDD15	XTdata
标签为 0	96	161
标签为 1	30	35

结束语 在教育与互联网相结合的背景下,评价学习交互质量,利用产生的学习交互数据改善学习者的学习表现和学习效果,将是未来教育发展的必然趋势。未来,研究者应用神经网络和表示学习等计算机技术对学习者的交互数据进行更为深入的挖掘分析,对在线教学进行干预,这是更为深入的技术应用方向。

本文将深度学习等技术应用于教育数据,首先建立清晰的在线学习动态交互网络模型,然后使用两个循环神经网络将网络中的学习者和学习资源节点嵌入到一个欧氏空间中,并根据嵌入结果提出对学习者在学习过程中交互质量的评价指标,用于判断学习者的学习效果是否达到预期。

在线学习交互质量评价的研究面临着两个主要问题:1)目前的在线教学平台数据仍存在一定的局限性,未能全面表示学习者的背景信息和学习行为信息;2)交互质量评价指标设计的理论依据和实验验证仍需要更多的教育学理论的支撑。未来将围绕这两个问题展开研究。

参 考 文 献

[1] KEEGAN D. Reintegration of the teaching acts[J]. Theoretical principles of distance education,1993;113-134.

[2] DOWMES S. Connectivism and connective knowledge:essays on meaning and learning networks[DB/OL]. National Research Council Canada. http://www.downes.ca/files/books/Connective_Knowledge-19May2012.pdf.

[3] PARKER A,PARKER S. Interaction:The vital conversation in online instruction[OL]. <https://eric.ed.gov/?id=ED541876>.

[4] ROSSI D,RENSBURG H,HARREVELD R,et al. Exploring a Cross-Institution research collaboration and innovation: deploying social software and web 2.0 technologies to investigate online learning designs and interactions in two Australian Universities[J]. Dental & Medical Problems,2012,5(2):1-11.

[5] BIGGS J. Testing:to educate or to select? [M]. Hongkong: Hong Kong Educational Publishing Company,1996.

[6] ALDERSON J C,WALL D. Does washback exist? [J]. Applied Linguistics,1993,14(2):115-129.

[7] SIEMENS G. Orientation:sensemaking and wayfinding in complex distributed online information environments[D]. Aberdeen:University of Aberdeen Doctoral Dissertation,2011.

[8] PRASHA S,SURAJ M,DUSTIN A,et al. Learning from dynamic user interaction graphs to forecast diverse social behavior [C]//Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM '19). 2019: 2033-2042.

[9] CAI R,BAI X,WANG Z,et al. Modeling sequential online inter-

active behaviors with temporal point process[C]// the 27th ACM International Conference. ACM,2018:873-882.

[10] FENG W,TANG J,LIU T X. Understanding Dropouts in MOOCs[J]. Proceedings of the AAAI Conference on Artificial Intelligence,2019,33:517-524.

[11] MOORE M G. Three types of interaction[J]. distance education new perspectives,1993,3(2):1-7.

[12] LAURILLARD D. Rethinking university teaching;a conversational framework for the effective use of learning technologies [M]. London:Routledge,2002.

[13] ROBLER M D,WIENCKW W R. Design and use of a rubric to access and encourage interactive qualities in distance courses [J]. The American Journal of Distance Education,2003,17(2): 77-98.

[14] WEI Z,CHEN L,XI J H. Research on the evaluation index system of interactive quality of web-based course teaching[J]. Open Education Research,2004(6):34-39.

[15] PEROZZI B,ALRFOU R,SKIENA S. DeepWalk;online learning of social representations[C]// ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2014:701-710.

[16] GROVER A,LESKOVEC J. Node2vec:scalable feature learning for networks[C]// The 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 855-864.

[17] RIBEIRO L F R,SAVARESE P H P,FIGUEIREDO D R. Struc2vec;learning node representations from structural identity [C]//Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM,2017.

[18] FU T Y,LEE W C,LEI Z. Hin2vec;explore meta-paths in heterogeneous information networks for representation learning [C]//Proceedings of the 2017 ACM on Conference on Information and Knowledge. ACM,2017.

[19] DAI H,WANG Y,TRIVEDI R,et al. Deep coevolutionary network;embedding user and item features for recommendation [J]. arXiv:learning. arXiv preprint arXiv:1609.03675. 2016.

[20] KUMAR S,ZHANG X,LESKOVEC J. Predicting Dynamic Embedding Trajectory in Temporal Interaction Networks[C]//the 25th ACM SIGKDD International Conference. ACM, 2019: 1269-1278.



WANG Xue-cen, born in 1996, postgraduate. Her main research interests include smart education and recommendation system.



ZHANG Yu, born in 1980, Ph.D, lecturer, is a member of China Computer Federation. His main research interests include big data in education, social networks, etc.